

Trabajo Práctico 1

Materia Laboratorio de Datos

Integrantes: Joaquín Viera, Luca Zanela, Nicolás Rozenberg

Nombre del Grupo: Pythonisos

Resumen

En el presente trabajo intentamos realizar un análisis de la variabilidad salarial del sector privado en relación a la actividad de trabajo, la provincia o departamento en el que se realiza, y la cantidad de operadores registrados que haya en dicha área. Buscamos responder algunas de las siguientes preguntas o ideas disparadoras:

- Cuantos menos operadores haya en un área, ¿mayor es el salario?
- ¿Es semejante la cantidad de operadores registrados en cada provincia? ¿Puede esto generar que existan asimetrías en los salarios de los trabajadores?
- Dentro de un mismo rubro de trabajo, ¿varía el salario dependiendo de la provincia/departamento en el que se realice?

A partir de los análisis y la observación de los gráficos, pudimos concluir que la Ciudad Autónoma de Buenos Aires posee un promedio salarial levemente por encima del resto de las provincias, y también un menor salario promedio de actividades relacionadas más al ámbito rural. Sin embargo, con los datos obtenidos, no podemos llegar a una respuesta concreta para las demás preguntas.

Índice

Resumen.....	1
Índice.....	1
Introducción.....	2
Diccionario de fuentes empleadas.....	2
Decisiones Tomadas.....	3
Procesamiento de Datos.....	3
Análisis de fuentes.....	3
Dependencias funcionales.....	4
Calidad de datos.....	5
Problema de obtener una clave primaria para los operadores.....	5
Problema de los valores indefinidos.....	5
Problema de localizar a cada operador del Padrón.....	5
Problema de determinar el sector productivo correspondiente a cada operador.....	6
Normalización.....	7
Análisis de Datos.....	9
Conclusiones.....	13
Anexo.....	14
1. Listado de departamentos sin operadores analizados.....	14

Introducción

El problema a resolver consiste en entender si existe “ ... cierta relación entre el desarrollo de la actividad y el salario promedio que perciben los trabajadores del sector privado en cada departamento de las provincias argentinas.”.

Para contestar esta pregunta, trabajamos con algunos dataframes obtenidos de la página de datos laborales del gobierno. Como dichos dataframes se encontraban en estados deplorables en términos de calidad de datos, el trabajo de limpieza y normalización resultó desafiante, pero su correcta realización nos permitió, posteriormente, manipular y analizar las bases de datos resultantes muy cómodamente. El análisis consistió en ir respondiendo preguntas breves a través de consultas SQL, y también ir graficando ciertas relaciones entre las variables involucradas.

Diccionario de fuentes empleadas

En negrita se encuentra el nombre adoptado en este informe para cada tabla original, extraída de su fuente correspondiente.

Padrón: Padrón de Operadores Orgánicos Certificados (Extraído de: <https://datos.magyp.gob.ar/dataset/padron-de-operadores-organicos-certificados>.)

Salarios: Salarios del sector privado (Extraído de https://www.datos.gob.ar/fa_IR/dataset/produccion-salarios-por-departamentopartido-sector-actividad/archivo/produccion_515b41b2-d008-42fa-a9d7-8a1bb26d04ab)

Localidades censales: Listado de las localidades censales según la base de datos censales del INSTITUTO NACIONAL DE ESTADÍSTICA Y CENSOS (INDEC) (Extraído de https://datos.gob.ar/ar/dataset/jgm-servicio-normalizacion-datos-geograficos/archivo/jgm_8.12)

Diccionario de departamentos: Listado de los códigos utilizados por INDEC para caracterizar los departamentos/partidos y provincias. (Extraído de <https://datos.produccion.gob.ar/dataset/puestos-de-trabajo-por-departamento-partido-y-sector-de-actividad/archivo/125bdc76-0205-417a-bf20-76d34dbe184b>)

Diccionario de Clae2: (Extraído de https://www.datos.gob.ar/fa_IR/dataset/produccion-salarios-por-departamentopartido-sector-actividad/archivo/produccion_8c7e4f21-750e-4298-93d1-55fe776ed6d4)

Decisiones Tomadas

A continuación, enumeramos las distintas decisiones que nos vimos obligados a tomar a lo largo del trabajo.

- En **Padrón** intercambiamos los valores para las filas 1182, 1234, 1235. Para el 1182, cambiamos el rubro a ELABORACION, FRACCIONAMIENTO, EMPAQUE Y ACOPIO; para las otras, SECADO, PELADO, ENVASADO Y ALMACENAMIENTO. Esto es porque todos esos rubros aparecían en distintas columnas en la fila original.
- Decidimos eliminar las filas que tengan a -99 como valor en w_median en **Salarios**, puesto que no aportan información.
- En la tabla **Padrón**, decidimos eliminar las columnas país y país_id, dado que todos los operadores que aparecen son de Argentina y consideramos que no aportaba información al análisis.
- Decidimos normalizar los valores INDEFINIDO (o cualquier variante) de todas las tablas con el valor np.nan, para que no haya ambigüedad.
- En la tabla **Padrón** decidimos indexar cada registro para utilizar el índice como clave. Esto lo hicimos luego de eliminar las filas que tuviesen todos los valores repetidos, ya que consideramos que eran datos mal cargados.
- Los valores de la columna rubro los reemplazamos por valores de clae2 que consideramos correspondientes. La asignación rubro -> clae2 está detallada en un diccionario en el archivo *limpieza_de_datos.py*.

Procesamiento de Datos

Análisis de fuentes

Enumeramos una serie de observaciones respecto de la estructura de las tablas fuente:

En **Localidades Censales** existe redundancia, puesto que en la misma tabla hay información sobre cada uno de los niveles en la jerarquía de divisiones políticas al que pertenece una localidad dada. En síntesis, la información sobre el municipio, el departamento y la provincia de cada localidad se repite para cada aparición de dicho municipio. Por lo tanto, decidimos dividir la fuente en varias tablas: Localidad, Municipio, Departamento, Provincia.

El **Diccionario de Clae2** se encuentra en 1FN, dado que, como los valores del atributo letra_desc son strings que describen una categoría, califican como valores atómicos a pesar de tener 'comas' que separan palabras. Igualmente, existe redundancia a partir de la presencia de esta misma columna, dado que cada valor de letra en el esquema está relacionado con un único valor de letra_desc. Por este motivo decidimos crear una nueva tabla Letra que establezca dicha relación entre ambas columnas.

Para que **Padrón** se encuentre en 1FN debimos eliminar la columna productos y crear una nueva relación Producto, que indique los productos con los que se relaciona cada tupla.

Dependencias funcionales

Definimos las dependencias funcionales de las tablas fuente luego de pasarlas a 1FN.

De la fuente **Padron:**

```
provincia_id -> provincia
categoria_id -> categoria_desc
certificadora_id -> certificadora_deno
id -> certificadora_id
id -> categoria_id
id -> localidad
id -> provincia_id
id -> departamento
id -> localidad
id -> rubro
id -> establecimiento
id -> razon_social
```

Donde ID es el atributo que agregamos artificialmente para identificar a los registros del padrón.

De la fuente **Salarios:**

```
codigo_departamento_indec -> id_provincia_indec
{fecha, codigo_departamento_indec, clae2} -> w_median
```

De la fuente **Localidades Censales:**

```
provincia_id -> provincia_nombre
departamento_id -> departamento_nombre
departamento_id -> provincia_id
municipio_id -> departamento_id
municipio_id -> municipio_nombre
id -> nombre
id -> categoria
id -> municipio_id
id -> departamento_id
id -> centroide_lat
id -> centroide_lon
id -> fuente
id -> funcion
```

De la fuente **Diccionario Clases:**

clae2 -> letra
clae2 -> clae2_desc
letra -> letra_desc

De la fuente **Diccionario Departamentos:**

codigo_departamento_indec -> nombre_departamento_indec
codigo_departamento_indec -> id_provincia_indec
id_provincia_indec -> nombre_provincia_indec

Calidad de datos

Enumeramos los problemas de calidad de datos que encontramos en las tablas fuente, y sus correspondientes resoluciones:

Problema de obtener una clave primaria para los operadores

A la hora de determinar la PK de **Padrón**, nuestro primer intento fue analizar si el establecimiento era único para cada registro. Lamentablemente, observamos que una gran cantidad de establecimientos poseían valor NaN, por lo que resultó imposible utilizar dicho atributo como PK. Consideramos la posibilidad de diferenciarlos gracias al atributo `razon_social`. Sin embargo, seguía habiendo repeticiones. A medida que fuimos agrandando el conjunto de atributos que pudiera funcionar como PK, llegamos a la conclusión de que lo más cómodo y prolijo iba a ser incorporar un id para cada operador, independientemente de si el establecimiento figuraba como NaN o no. Dicho id nos permitió tener una PK más compacta.

Problema de los valores indefinidos

Observamos que no existe uniformidad en la manera de nombrar a los valores indefinidos, ni siquiera dentro de una misma tabla (en el caso de **Padrón**). Para resolver esto, reemplazamos dichos valores en todas las tablas por `np.nan`, primero habiendo identificado todos los nombres que podían recibir los valores indefinidos.

Problema de localizar a cada operador del Padrón

Uno de los mayores problemas que enfrentamos a la hora de realizar la limpieza de los datos fue localizar a cada operador en el **Padrón**. Ésto se debe a que se encontró una gran cantidad de problemas de calidad, principalmente en cuanto a consistencia y completitud de los datos, tanto en el **Padrón** como en las fuentes secundarias de localización (**Localidades Censales** y **Diccionario de Departamentos**). Debajo listamos los problemas encontrados y cómo los fuimos solucionando.

- En el **Padrón** existe información sobre el nombre del departamento donde está localizado cada operador. Esto podría ser un problema de modelo, ya que el nombre de un departamento no debería tener una función de clave foránea. El valor de la columna 'departamento' lo hemos descartado luego para obtener las tablas

definitivas. Pero más allá de eso, encontramos que no existían correspondencias entre los nombres de departamento en la fuente **Padrón** y en **Localidades Censales**. Ésto se debe a que los nombres en la primera estaban escritos en mayúscula, mientras que en la segunda no, y además había diferencias de ortografía. Para resolver ésto, pasamos a mayúscula y estandarizamos, mediante la librería `unidecode`, todas las columnas que denoten nombres de divisiones políticas entre estas dos tablas.

- Encontramos que existía una pequeña parte de los departamentos registrados en **Localidades Censales** cuyo ID no poseía correspondencia con los de **Diccionario Departamento**, por lo que es un pequeño error de consistencia. Éstos casos los corregimos a mano, tomando los valores de **Diccionario Departamento**, ya que asumimos mayor confiabilidad en este último.
- Luego de normalizar, encontramos que sólo un 55% de los operadores poseían una correspondencia en su departamento con un departamento de la tabla de **Localidades Censales**. Encontramos que existían nombres de departamento en el **Padrón** que en verdad correspondían a nombres de localidades, y también otros que correspondían a municipios. Fuimos creando un diccionario, que para cada valor actual de la columna departamento del operador, le asignaba el valor del ID del departamento correspondiente. Para los casos donde el valor era una localidad, se obtuvo el ID de su departamento correspondiente, y éste valor pasó a la columna localidad. Finalmente creamos una nueva columna, `departamento_id`, incluyendo el departamento donde se encuentra el operador. Eliminamos aquellos operadores a los cuales no pudimos encontrarles un departamento, ya que representaban sólo un 8% del total.
- Sin embargo, todavía el 75% de los valores de localidad en los operadores correspondía a valores vacíos, o valores sin correspondencias en las **Localidades Censales**, por lo que es otro error de completitud. Para los segundos, vaciamos su valor. Y luego, ya teniendo información sobre el departamento de cada operador, elegimos naturalmente asignarle como localidad, a la localidad cabecera correspondiente a su `departamento_id`.
- Ya teniendo información sobre la localidad de cada operador, creamos una nueva columna `localidad_id` en el **Padrón**, con el ID correspondiente a la localidad de cada operador.

Problema de determinar el sector productivo correspondiente a cada operador

Para realizar nuestro análisis, necesitamos que la información sobre el sector productivo de cada operador (representada en la fuente original con la columna rubro), se corresponda a alguna actividad registrada por algún ente oficial (en este caso, el INDEC). Los sectores productivos pueden ser representados por un identificador llamado `clae2`. Sin embargo, observamos que los valores de la columna rubro, ningún valor tenía correspondencia con la denominación de cada actividad registrada por el INDEC. Por lo tanto, decidimos asignarle manualmente a cada valor único de la columna rubro, un `clae2` correspondiente. Entonces, cada operador comenzó a tener un nuevo `clae2`.

Normalización

Para conseguir que los esquemas estén en 3FN, descompusimos las tablas que teníamos luego de pasar los dataframes fuente a 1FN. La descomposición produjo las siguientes tablas:

- Operador
- Provincia
- Certificadora
- Departamento
- Municipio
- Localidad
- Rubro
- Letra
- Producto

Construimos el siguiente DER para representar las relaciones existentes entre las distintas entidades consideradas:

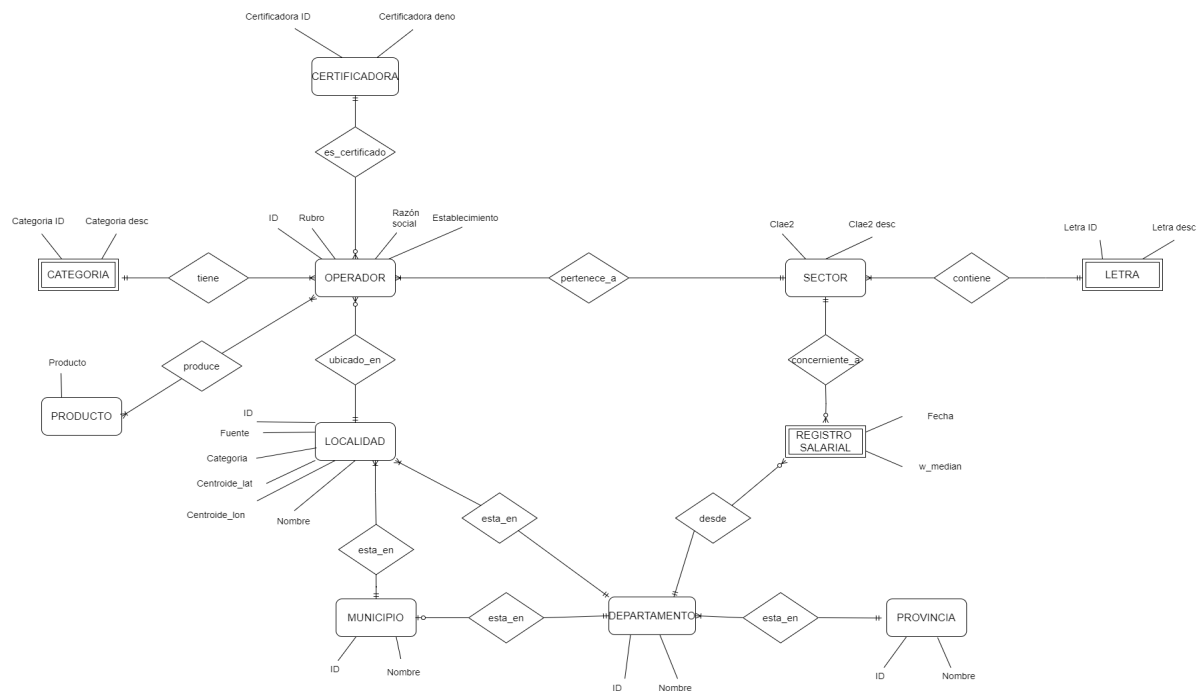


Figura 1: Diagrama Entidad-Relación

Se detalla en el siguiente MER la forma en la cual se descompusieron las tablas originales:

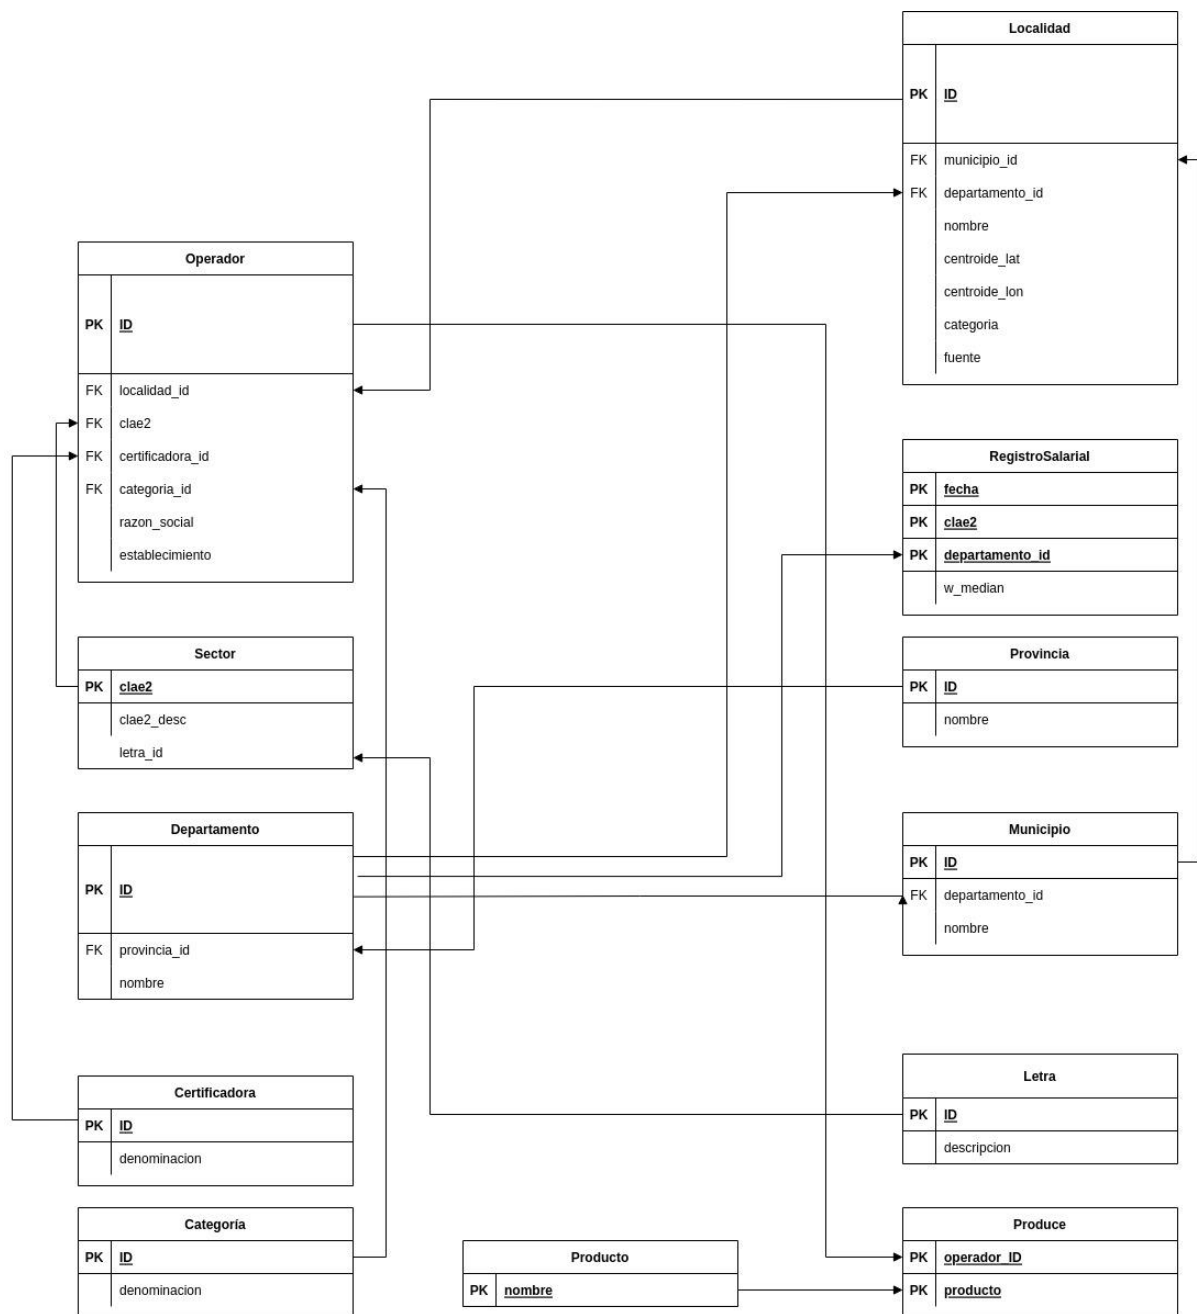


Figura 2: Modelo Entidad-Relación

Esta descomposición provocó que se perdieran las dependencias funcionales de atributos que fueron eliminados o cambiados por cuestiones de calidad de datos (por ejemplo, un id de un operador ya no determina el rubro, sino clae2).

El conjunto de dependencias funcionales resultantes para cada tabla son únicamente las que la clave privada aparece del lado izquierdo. Ésto implica que no existen dependencias, o bien parciales entre claves privadas, o bien transitivas entre atributos de claves primarias por atributos no primos. El único caso en donde existe una clave primaria compuesta con atributos no primos es en la tabla de RegistroSalarial. Y la única dependencia funcional en esta tabla es {fecha, departamento_id, clae2} -> w_median, por lo que cumple con la 3FN.

Análisis de Datos

Comenzamos por calcular la cantidad de operadores certificados por provincia. En el dataframe resultante, vimos que aparecían 24 registros, uno por provincia, y todos con cantidades de operadores mayores a 0. Concluimos que no hay provincias sin operadores certificados.




Gráfico 1: Cantidad de operadores por provincia

Luego, nos hicimos la misma pregunta con respecto a los departamentos. Generamos un dataframe que tuviese, para cada departamento, la cantidad de operadores orgánicos certificados registrados en dicho departamento, y lo filtramos para quedarnos con los departamentos que tuviesen 0 operadores. Observamos que hay 247 departamentos sin operadores. El listado se encuentra en la sección 1 del anexo.

Continuamos analizando la actividad con más operadores, que resultó ser ELABORACION DE PRODUCTOS ALIMENTICIOS, cuyo c1ae2 es 10, con un total de 906 operadores. El salario promedio de esta actividad en 2022 fue de \$251786.07, considerando todos los departamentos.

Calculamos el promedio anual de los salarios registrados, para los años desde 2014 hasta 2022. Obtuvimos la información que se muestra en la tabla 1:

Promedio	Año
9847.02	2014
12921.10	2015
17137.12	2016
22224.47	2017
28170.58	2018

40683.17	2019
55801.30	2020
83403.60	2021
144981.37	2022

Tabla 1: Promedio salarial nacional por año.

El desvío de dichos promedios es de \$43928.93, lo cual es un valor muy elevado. Haciendo el mismo análisis a nivel provincial, obtuvimos que el desvío de los promedios salariales por provincia es de \$31143.97. El hecho de que el desvío sea alto en ambos casos se debe a la variación que existe entre los salarios año a año, producto de la inflación.

Podríamos decir que una manera de que los promedios salariales sean comparables a lo largo de los años es incorporando al análisis una tabla que indique la inflación interanual para cada uno de los años considerados. Con esa database a mano, se podría "actualizar" todos los salarios anteriores a 2022 multiplicándolos sucesivamente por las inflaciones interanuales que haya habido en los años comprendidos entre el año considerado y 2022. De esta manera, los sueldos serían, en algún sentido, equiparables a lo largo de los años. Igualmente, este análisis tampoco es del todo completo, dado que, lamentablemente, las actualizaciones salariales no suelen seguir la inflación. Algo que se podría hacer para verificar efectivamente si esto sucede o no, es conseguir datos históricos de la inflación interanual, y analizar la correlación que existe entre la proporción de aumento salarial interanual y la inflación interanual: una correlación positiva indicaría un aumento salarial por encima de la inflación, mientras que una correlación negativa correspondería a un aumento salarial por debajo de la inflación.

Intentamos visualizar si la distribución de los salarios varía de manera considerable dependiendo de la provincia.

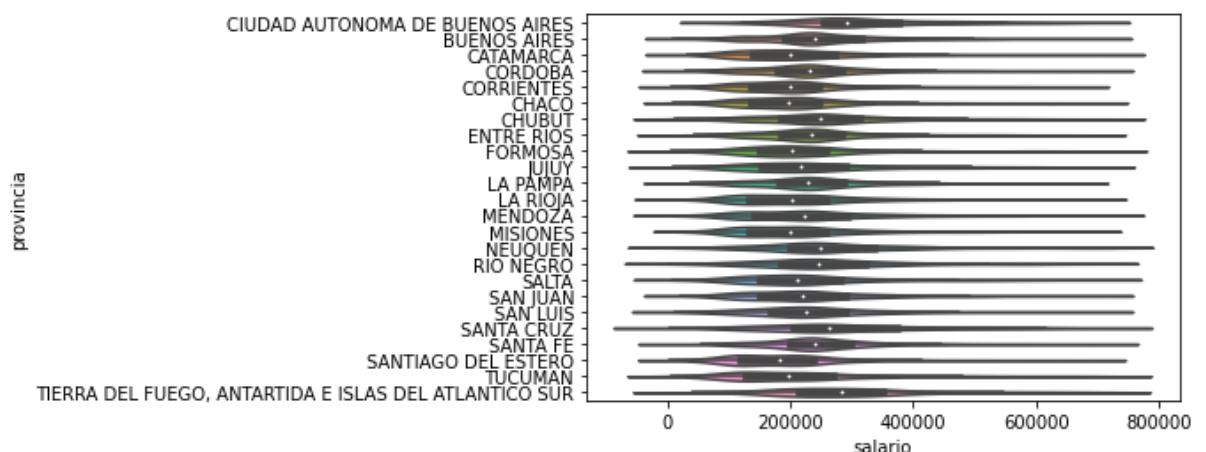


Gráfico 2: Distribución de los salarios promedio de diciembre de 2022 por cada provincia

Se puede observar que la Ciudad Autónoma de Buenos Aires posee una media levemente mayor a la del resto de las provincias. ¿Acaso esto es un indicio de centralismo?

En cuanto a la cantidad de productos, no se puede observar una distribución clara de acuerdo a cada provincia. La mayoría tiene una media de entre 1 y 2 por operador, como se muestra en el gráfico 2.

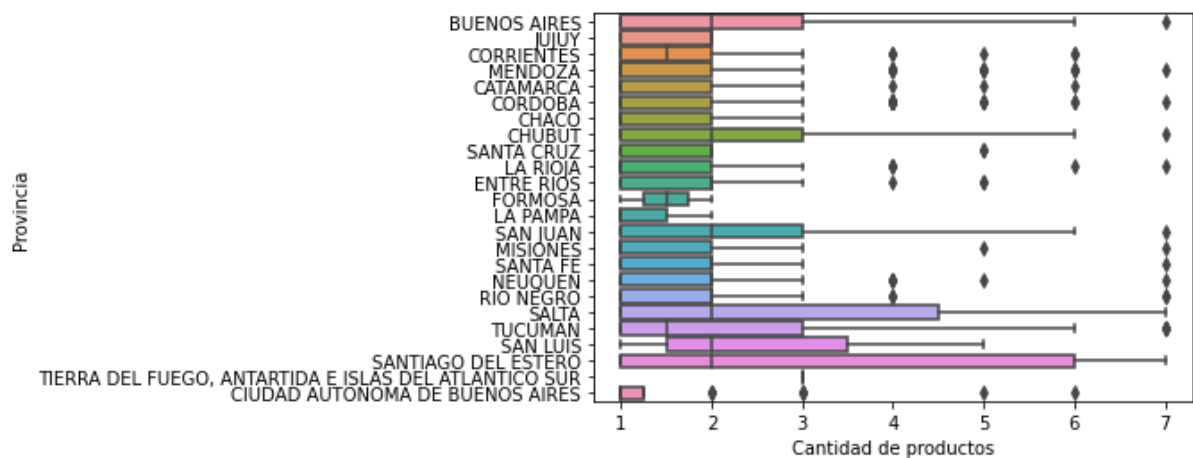


Gráfico 3: Cantidad de productos producidos por operador por provincia, descartando outliers por fuera del cuantil 0.97.

Intentando visualizar la existencia de alguna correlación entre el salario promedio de una actividad y la cantidad de operadores de dicha actividad, realizamos el siguiente gráfico:

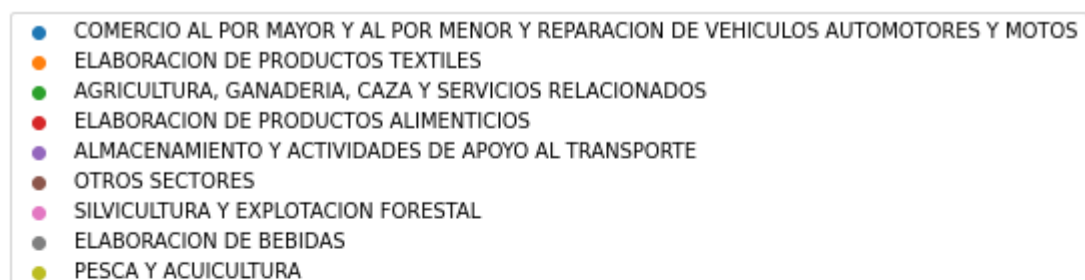


Gráfico 4: Comparación de las variables “Cantidad de operadores” (eje y) y “Salario promedio” por cada actividad

Se puede observar que, en general, las actividades del ámbito más rural (como por ejemplo, Agricultura, Ganadería, Caza y Servicios Relacionados o Silvicultura) poseen en general menor salario promedio. Sin embargo, como no conseguimos observar ninguna correlación entre estas dos variables, pensamos en graficar la misma relación, pero agrupando también por provincia. Obtuvimos el siguiente gráfico:

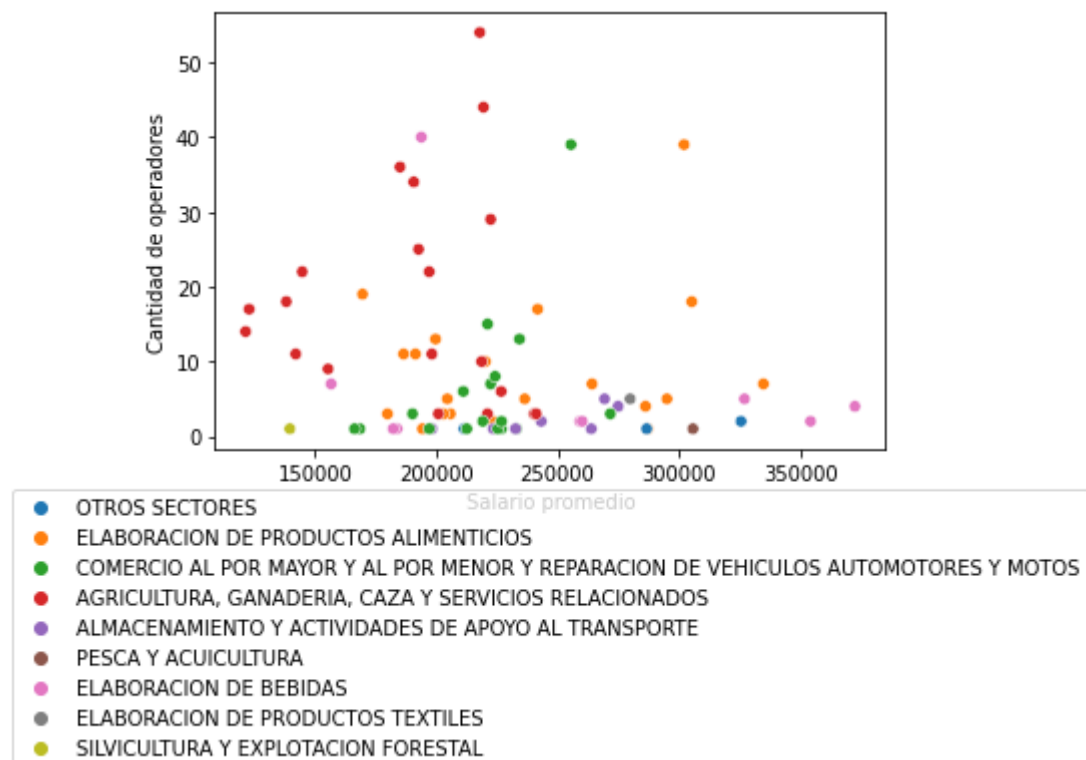


Gráfico 5: Comparación de las variables “Cantidad de operadores” (eje y) y “Salario promedio” (eje x). Cada punto representa un par (provincia, actividad).

Seguimos sin poder observar una correlación clara entre las variables mencionadas. Pero, en general, la observación que realizamos sobre las actividades del ámbito rural se sigue manteniendo.

Pensamos en graficar la relación entre las mismas variables, pero agrupando únicamente por provincia, para intentar visualizar si existen asimetrías en los salarios promedio y su relación con la cantidad de operadores registrados en cada provincia.

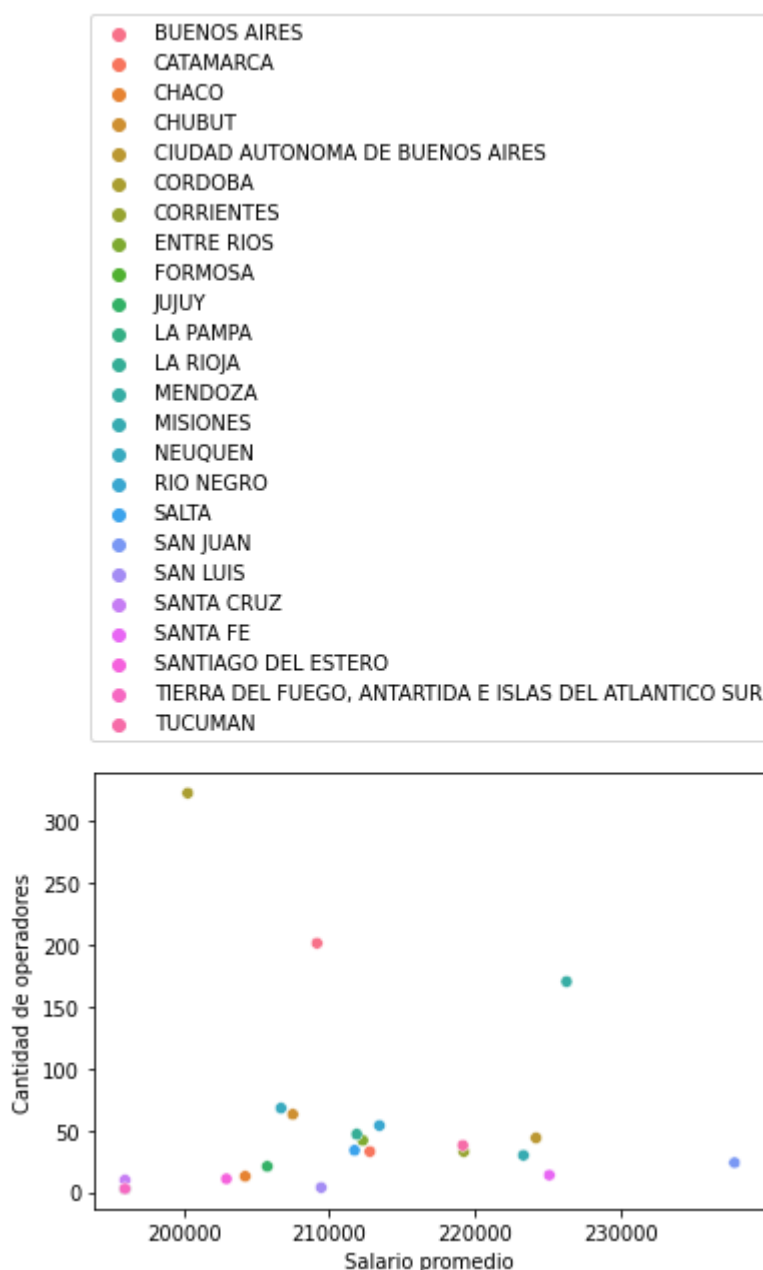


Gráfico 6: Comparación de las variables “Cantidad de operadores” (eje y) y “Salario promedio” (eje x), por provincia

Conclusiones

Pudimos concluir que, en base a los datos analizados, el salario promedio de la Ciudad Autónoma de Buenos Aires es mayor al del resto de las provincias.

No conseguimos entender si existe una correlación clara entre la cantidad de operadores y el salario promedio de una actividad en una determinada provincia (ni tampoco a nivel nacional). Pensamos que esto puede deberse a que el registro de operadores posee datos solamente de actividades vinculadas a la agricultura y ganadería, y sus derivados. Otra razón es que, al no tener certeza de la correctitud de las actividades registradas por el INDEC que les asociamos a cada operador, es muy probable que a una gran cantidad no le corresponda su actividad, para la cual fueron consultados a la hora de

crear los registros salariales. Esto nos impidió contestar la pregunta de si a mayor salario se registran menos operadores. Sin embargo, sí pudimos observar cierta agrupación de actividades más rurales dentro de salarios más bajos.

Por otra parte, pudimos observar que la cantidad de operadores orgánicos certificados no posee una distribución homogénea a lo largo y ancho del país. Córdoba, Buenos Aires y Mendoza son las provincias con mayor cantidad de operadores. Creemos que esto tiene sentido, dadas las condiciones naturales del suelo de dichas provincias. A su vez, al graficar la relación entre cantidad de operadores y salario promedio de cada provincia, no pudimos observar una correlación clara.

Anexo

1. Listado de departamentos sin operadores analizados

BALCARCE, ARRECIFES, ALMIRANTE BROWN, BERAZATEGUI, BERISSO, BRAGADO, BRANDSEN, CAPITAN SARMIENTO, CARLOS CASARES, CARLOS TEJEDOR, CASTELLI, CHASCOMUS, DAIREAUX, DOLORES, ENSENADA, ESCOBAR, JOSE M. EZEIZA, FLORENCIO VARELA, GENERAL ARENALES, GENERAL GUIDO, GENERAL JUAN MADARIAGA, GENERAL LA MADRID, GENERAL LAVALLE, GENERAL PINTO, GENERAL RODRIGUEZ, CIUDAD LIBERTADOR SAN MARTIN, GENERAL VIAMONTE, GENERAL VILLEGAS, HURLINGHAM, JOSE C. PAZ, LA COSTA, LA MATANZA, LAPRIDA, LEANDRO N. ALEM, LOBERIA, LOMAS DE ZAMORA, MAGDALENA, MAR CHIQUITA, MARCOS PAZ, MERLO, MONTE, MONTE HERMOSO, MORENO, MORON, NAVARRO, NECOCHEA, PEHUAJO, PELLEGRINI, PILA, PINAMAR, QUILMES, ROJAS, ROQUE PEREZ, SALADILLO, SALTO, SALLIQUELO, SAN ANDRES DE GILES, SAN CAYETANO, SAN FERNANDO, SAN MIGUEL, SAN VICENTE, SUIPACHA, TAPALQUE, TIGRE, TORDILLO, TORNQUIST, TRENQUE LAUQUEN, TRES DE FEBRERO, TRES LOMAS, VICENTE LOPEZ, ANCASTI, ANDALGALA, ANTOFAGASTA DE LA SIERRA, CAPAYAN, EL ALTO, FRAY MAMERTO ESQUIU, PACLIN, VALLE VIEJO, MINAS, POCHO, PRESIDENTE ROQUE SAENZ PENA, PUNILLA, RIO CUARTO, RIO SEGUNDO, SAN ALBERTO, SOBREMONTA, TERCERO ARRIBA, TOTORAL, TULUMBA, UNION, BERON DE ASTRADA, CORRIENTES CAPITAL, ESQUINA, ITATI, LAVALLE, PASO DE LOS LIBRES, SALADAS, SAN COSME, SAN ROQUE, SANTO TOME, SAUCE, COMANDANTE FERNANDEZ, 12 DE OCTUBRE, FRAY JUSTO SANTA MARIA DE ORO, GENERAL DONOVAN, INDEPENDENCIA, MAYOR LUIS J. FONTANA, O'HIGGINS, PRESIDENCIA DE LA PLAZA, SARGENTO CABRAL, TAPENAGA, TELSEN, DIAMANTE, FELICIANO, GUALEGUAYCHU, ISLAS DEL IBICUY, NOGOYA, TALA, FORMOSA, PATINO, PILAGAS, PIRANE, COCHINOCA, DR. MANUEL BELGRANO, HUMAHUACA, PALPALA, SAN ANTONIO, SANTA CATALINA, SUSQUES, TUMBAYA, VALLE GRANDE, YAVI, ATREUCO, LA PAMPA CAPITAL, CATRILO, CONHELO, CURACO, CHALILEO, CHAPALEUFU, CHICAL CO, GUATRACHE, HUCAL, LIHUEL CALEL, LIMAY MAHUIDA, MARACO, PUELEN, RANCUL, REALICO, TRENEL, CASTRO BARROS, CHAMICAL, FAMATINA, GENERAL ANGEL V. PENALOZA, GENERAL JUAN F. QUIROGA, GENERAL LAMADRID, VINCHINA, ROSARIO VERA PENALOZA, SAN BLAS DE LOS SAUCES, SANAGASTA, CANDELARIA, CONCEPCION, ELDORADO, GUARANI, ALUMINE, CATAN LIL, COLLON CURA, CHOS MALAL, HUILICHES, LACAR, LONCOPUE, LOS LAGOS, NORQUIN, PEHUENCHES, PICUN LEUFU, PICUNCHES,

ZAPALA, CONESA, NORQUINCO, VALCHETA, LA CALDERA, LA CANDELARIA, LA POMA, LA VINA, MOLINOS, ROSARIO DE LERMA, SANTA VICTORIA, SAN JUAN CAPITAL, IGLESIA, JACHAL, VALLE FERTIL, ZONDA, GENERAL PEDERNERA, GOBERNADOR DUPUY, CORPEN AIKE, CASTELLANOS, GENERAL LOPEZ, GENERAL OBLIGADO, LAS COLONIAS, VERA, AGUIRRE, ALBERDI, COPO, CHOYA, GENERAL TABOADA, GUASAYAN, JIMENEZ, JUAN F. IBARRA, LORETO, MITRE, SALAVINA, SILIPICA, BURRUYACU, CRUZ ALTA, SIMOCA, LEALES, USHUAIA, VILLA GESELL, EMPEDRADO, GOYA, LAISHI, RINCONADA, VILLA CONSTITUCION, GARAY, IRIONDO, TAFI DEL VALLE, CORONEL DE MARINA LEONARDO ROSALES, PRESIDENTE PERON, SAN LUIS DEL PALMAR, QUITILIPÍ, MATACOS, TILCARA, LOVENTUE, TOAY, IRUYA, ATAMISQUI, BANDA, ROBLES, TRANCAS, PUNTA INDIO, LOS ANDES, ULLUM, JUAN MARTIN DE PUEYRREDON, LAGO ARGENTINO, OJO DE AGUA, SAN CRISTOBAL, MBURUCUYA, 2 DE ABRIL